

Analyse en composantes principales.

Mini projet 1 (statistiques exploratoires). date limite: 13 décembre 2013.

Le jeu de données étudié est disponible sur http://math.univ-lille1.fr/~marbaclo/.

Le CESP (Centre d'Étude des Supports de Publicité) a relevé dans une enquête en 1991/1992 des temps en minutes d'activités quotidiennes en regard à certaines caractéristiques socio-économiques. Chaque individu correspond en fait à un groupe d'homme actifs ayant des points communs quand à l'âge (J pour jeune, M pour moyen et A pour âgé), au niveau d'éducation (1 pour primaire, 2 pour secondaire et 3 pour supérieur) et au type d'agglomératoin (rur pour rural, moy pour villes moyennes, imp pour villes importantes, par pour l'agglomération parisienne et mix pour groupes mixtes).

La signification des variables est : Somm-Sommeil, Repo-Repos, Trar-Travail rémunéré, Mena-Ménage, Visi-Visite à amis, Jard-Jardinage-Bricolage, Lois-Loisirs extérieurs, Disq-Disque cassette, Lect-Lecture livre, Cour-Courses démarches, Prom-Promenade, Pied-Déplacement à pieds, Voit-Déplacement en voiture et Freq-Fréquentation média.

Les données se trouvent dans le fichier CESP.txt. On vous demande de faire l'étude de ce jeu de données et de fournir un rapport type **professionel**. Vous devez expliquer votre démarche qui doit être compréhensible par un néophyte. Les détails techniques (calculs, codes...) sont en annexes du rapport. Le choix du logiciel vous appartient.

Voici quelques étapes pour vous aider (non exhaustives!) :

- 1. Effectuer l'ACP en donnant le même poids à chaque individu. Justifier, au regard des données, de la métrique à retenir.
- 2. Interpréter les résultats de l'ACP.
- 3. On se propose de prendre deux variables supplémentaires : Reps-Repas chez soi et Repr-Repas au restaurant. Les données sont disponibles dans le fichier CESPsup.txt. Projeter ces deux variables dans les plans de corrélations. Ces variables confirment elles les conclusions précédentes.